

Hy3-ContestLens

过程评估与错误定位

评测结果、有效性验证与人工抽检分析报告

数据截止：2026-09-11

项目属性：个人/活动作品，非腾讯官方发布

任务方向：可验证场景——算法竞赛解题过程评估与错误定位

可评测题闭环	答案至少一次 AC	严格成功至少一次	运行级严格成功
63/63 (100.0%)	53/63 (84.1%)	44/63 (69.8%)	51/86 (59.3%)

验证状态

本报告已重算完整运行、难度分层、错误分布和修复收益，并生成 10 条抽检工作表。正式定位准确率与误报率仍待双人人工盲标；AI 辅助预审结果仅用于发现风险，不作为人工真值。

证据快照：129 条数据库 run、86 条已结束工作流、14,433 条事件、172 条初始/修复版本记录。

执行摘要

项目已为 63 道可自动评测题形成闭环。按题目历史至少一次口径，答案 AC 覆盖为 53/63 (84.1%)，答案与过程双通过覆盖为 44/63 (69.8%)。该口径反映累计覆盖，不等于一次统一实验的通过率。

全库 86 条已结束记录中，答案准确率 74.4%，过程正确率 70.9%，严格成功率 59.3%。另有 13 条答案 AC 但过程无效，证明“只看 Judge AC”会高估可解释性与推理质量。

发现	证据	含义
修复产生可测收益	严格成功由 41/86 升至 51/86	45 条初始非严格成功记录中，10 条恢复为双通过
临界点位于省选档	省选/NOI-严格成功 1/9；NOI/CTS 为 0/4	高难度下过程证明、实现和资源约束同时成为瓶颈
错误以过程错位为主	过程无效 13 条，实现不一致 11 条	两类合计占非严格成功记录 68.6%
首错定位仍不稳定	辅助预审 3/6 完全匹配	赛道修建三次 WA 均未定位 S4 的贪心反例
存在上下文型误报	金币 I/O 告警经复核为误报	Critic 未看到工作流级强制约束

最重要的解释边界

SQLite 的 COMPLETED 只表示工作流结束。活动脚本的 fully_passing 只比较测试点，不要求过程正确。因此本报告全部重新按严格成功口径计算。

1. 评测目标与数据范围

1.1 对应任务要求

本项目对应任务 2 “可验证场景：过程评估与错误定位”。题目具有标准答案与自动判定方式，应用需同时评价最终答案、推理过程、首个错误步骤和错误类型，并识别答案正确但过程不能支撑结论的样本。任务还要求输出最终答案准确率、过程正确率、错误类型分布、难度分层、定位准确率、误报率及人工抽检记录。

1.2 数据快照

对象	数量	说明
题库目录	74 题	两轮 campaign 的 catalog_problem_count
排除	11 题	8 题仅样例数据，3 题比较器未接入
可自动评测	63 题	全部至少有一条 status=COMPLETED 结果
数据库 run	129	COMPLETED 86; FAILED 36; CANCELLED 4; CREATED 3
事件	14,433	覆盖全部 129 个 run
版本级记录	172	初始 86; 修复/证明版本 86
人工标注	0	annotation_tasks=0、annotations=0、benchmarks=0

22 条历史结果没有在有 result_json 中固化难度。本报告使用当前 manifest 的洛谷难度回填，并在数据表中保留 difficulty_source 字段。

1.3 指标定义

指标	定义	分母
最终答案准确率	最佳提交 Judge verdict=AC 的记录数	已结束工作流记录
过程正确率	最佳提交 diagnosis.process_correct=true 的记录数	已结束工作流记录
严格成功率	compile=OK、Judge=AC 且 process_correct=true	已结束工作流记录
题目覆盖率	每题至少一次历史记录达到条件	63 道可自动评测题
定位准确率	机器首错步骤与人工真值完全一致	人工确认的错误答案样本
告警误报率	机器判过程有问题、人工确认过程正确	答案正确且被机器告警的样本

2. 过程评估方法设计

评估链路由五个互补层次组成：Solver 输出固定步骤 ID、依赖、不变量、依据、复杂度、边界和代码映射；Algorithm Critic 与 Code Critic 在确定性 Judge 之前并行盲审；Judge 通过编译和私有测试给出 AC/WA/TLE/MLE/RE 等可执行证据；融合器优先选择拓扑序最早的 CONTRADICTED 步骤并归类错误；修复器以最佳版本、反例和失败记忆生成候选，再重新编译、判题和评审。

这种组合把“结果是否正确”与“过程是否成立”分离：确定性 Judge 提供高置信答案真值，双路 Critic 负责不可直接由测试覆盖的证明和代码映射问题，修复轨迹则验证定位是否能转化为实际改进。

阶段	核心证据	主要防错
结构化求解	步骤、依赖、不变量、代码映射	减少“只有答案、无法定位”
算法盲审	逐步骤 SUPPORTED/CONTRADICTED	识别证明缺口、错误算法、幻觉
代码盲审	源码与 step map 对照	识别实现不一致、边界与资源问题
确定性 Judge	编译、测试点、首个输出差异与资源标志	提供最终答案客观判定
证据融合与修复	首错、类型、反例、回归、最佳版本	防止错误方向重复修补

3. 完整评测结果

3.1 运行级结果

指标	初始版本	最佳版本	变化
答案正确	53/86 (61.6%)	64/86 (74.4%)	+12.8 个百分点
过程正确	54/86 (62.8%)	61/86 (70.9%)	+8.1 个百分点
严格成功	41/86 (47.7%)	51/86 (59.3%)	+11.6 个百分点
答案正确但过程无效	—	13/86 (15.1%)	揭示 Judge-only 高估

修复模块使严格成功净增 10 条。以初始不满足严格成功的 45 条为分母，恢复率为 22.2%。该指标只说明现有修复预算下的恢复，不代表所有失败都可修复。

3.2 题目级累计覆盖

指标	数量	比例	解释
workflow 闭环	63/63	100.0%	每题至少一条已结束结果
答案至少一次 AC	53/63	84.1%	可含问题多次尝试
至少一次严格成功	44/63	69.8%	答案与过程同时通过

为什么同时报告两种口径

86 条运行记录适合衡量重复运行中的稳定性；63 道题的至少一次覆盖适合说明项目累计完成度。前者受问题重复影响，后者受多次尝试的最佳结果偏置影响，不能互相替代。

3.3 两轮 campaign 重算

活动	已结束	答案 AC	过程正确	严格成功	答案 AC/过程无效
collection-20260910T103603Z	39	35/39 (89.7%)	32/39 (82.1%)	32/39 (82.1%)	3
collection-20260911T013612Z	8	7/8 (87.5%)	7/8 (87.5%)	7/8 (87.5%)	0

表中只统计 campaign_entry_status=COMPLETED 的运行；首轮另有 8 条重启后失败和 1 条取消，因此不能把 32/39 外推为全部已启动任务的单次成功率。

4. 难度分层与能力临界点




图 1 题目级历史至少一次答案 AC 与严格成功覆盖率。

难度	题目数	答案 AC 覆盖	严格成功覆盖	运行级严格成功
入门	3	3/3 (100.0%)	3/3 (100.0%)	100.0%
普及-	9	9/9 (100.0%)	9/9 (100.0%)	100.0%
普及	11	11/11 (100.0%)	11/11 (100.0%)	82.4%
普及+/提高-	12	11/12 (91.7%)	10/12 (83.3%)	68.8%
提高	9	8/9 (88.9%)	5/9 (55.6%)	57.1%
提高+/省选-	6	6/6 (100.0%)	5/6 (83.3%)	71.4%
省选/NOI-	9	5/9 (55.6%)	1/9 (11.1%)	9.1%
NOI/NOI+/CTS	4	0/4 (0.0%)	0/4 (0.0%)	0.0%

入门、普及-、普及三档的题目级严格成功覆盖均为 100%。普及+/提高-降至 83.3%，提高档为 55.6%；提高+/省选-因样本仅 6 题出现 83.3% 的反弹。持续性断崖从省选/NOI-开始：答案 AC 覆盖 55.6%，严格成功仅 11.1%；NOI/NOI+/CTS 的 4 题答案 AC 与严格成功均为 0。

临界点结论

模型能力在省选/NOI-开始明显下降，并在 NOI/CTS 档进入当前评测配置下的不可稳定求解区间。由于各档样本量为 3-12 题，结论用于定位工程边界，不作统计显著性宣称。

5. 错误类型与失败模式




图 2 35 条非严格成功运行的机器诊断分布。

机器错误类型	数量	占比	解释
RESULT_CORRECT_PROCESS_INVALID	13	37.1%	Judge AC, 但证明、步骤或代码映射不能支撑结论
IMPLEMENTATION_MISMATCH	11	31.4%	过程看似成立, 实际代码或判题结果与过程不一致
COMPLEXITY_TLE	8	22.9%	算法或实现的资源复杂度超出限制
RUNTIME_ERROR	2	5.7%	运行期异常或执行失败
WRONG_ALGORITHM	1	2.9%	算法核心假设或递推错误

过程无效与实现不一致合计 24/35 (68.6%)，说明失败主要发生在“解释—实现—可执行结果”的衔接处。复杂度/TLE 为 8/35，集中出现在高难度档。机器只将 1 条最佳结果归为 WRONG_ALGORITHM，但抽检中三条赛道修建初始版本均可由同一反例归入错误算法，显示机器分类偏向保守的 IMPLEMENTATION_MISMATCH。

6. 有效性验证与人工抽检

6.1 验证样本构造

本次从严格成功记录中筛出所有发生过修复的 10 条运行，并取其初始版本作为配对验证样本。最终严格成功提供了“问题可被修复”的后验依据；初始判题、过程评估、修复差异和最终全通过结果共同构成复核证据。样本包括 6 条错误答案与 4 条答案正确但机器判过程有问题的记录。

抽样限制

该集合是目的性样本，偏向可修复案例，不是随机抽样；辅助复核由 Codex 完成，不是人工盲标。因此 50.0% 和 25.0% 只能作为风险信号。

6.2 辅助预审结果

验证项	样本	匹配/误报	辅助结果	正式状态
错误答案首错完全匹配	6	3	50.0%	待双人人审
正确答案告警误报	4	1	25.0%	待双人人审
正确答案告警中的真实问题	4	3	75.0%	待双人人审

6.3 样本级抽检记录

题目	类别	机器首错	辅助复核	辅助真值首错	结论
赛道修建	错误答案定位	未定位	存在过程问题	S4	首错应定位到 S4；评估器仅给出 IMPLEMENTATION_MISMATCH 且未定位，属于定位漏检。
赛道修建	错误答案定位	未定位	存在过程问题	S4	首错应定位到 S4；评估器把错误归为实现不一致但没有给出首错步骤。
赛道修建	错误答案定位	未定位	存在过程问题	S4	首错应定位到 S4；双路评审均把有反例的配对策略误判为正确。
铺设道路	正确答案告警	S3	存在过程问题	S3	真实过程问题，S3 的单调性不变量错误；不是误报。
金币	正确答案告警	S1	过程正确	无	评估器误报。S1 对 I/O 约束来源的措辞不精确，但执行动作与 workflow 强制要求一致，不构成解题过程失效。
魔法阵	正确答案告警	R6	存在过程问题	R5	存在真实过程瑕疵，但评估器首错定位偏晚：最早的可证伪陈述在 R5，而不是 R6。
字符串匹配	正确答案告警	S6	存在过程问题	S6	真实过程问题，S6 的文字步骤漏写初始插入 g[1]，与实际正确代码不一致。
建造军营	错误答案定位	S8	存在过程问题	S8	定位正确。S8 的树 DP 漏计当前分量权重，反例和修复轨迹均支持该结论。
廊桥分配	错误答案定位	S2	存在过程问题	S2	定位正确。S2 复用最早释放的编号，而不是最小空闲编号，破坏了前缀计数含义。
超速检测	错误答案定位	S3	存在过程问题	S3	定位正确。S3 对负加速度车辆错误假设判定谓词全局单调。

完整证据、运行路径和待填写的人审字段见配套工作簿“人工抽检”工作表与 manual_audit_records.csv。

7. 典型案例分析

7.1 铺设道路：成功识别答案正确但证明失效

run_Uzytk8n4cDbIWHh 的初始代码通过 10/10 测试，但步骤 S3 声称正差分和在每次操作下单调。对 $d=[2,1,1]$ 在区间 $[2,2]$ 执行一次合法操作后，正差分从 2 增加到 3，直接否定该不变量。评估器将其标为 RESULT_CORRECT_PROCESS_INVALID 并定位到 S3，后续修复证明后达到严格成功。此例证明过程评估能捕捉 Judge 无法发现的论证缺陷。

7.2 赛道修建：三次共享盲点导致首错漏检

run_Dwq5kWBqPd8K3Tqb、run_nPPFL5vXxjog7GZ8、run_R9reSD2WJqZJHWd9 的初始版本分别通过 16/20、12/20、16/20，但融合诊断均给出 process_correct=true、first_error_step_id=null。S4 使用最小链与最大链直接配对，只最大化当前配对数，没有保证同等配对数下的上行剩余链最大。候选链 $[1,1,2]$ 、阈值 2 时，原策略配对 1+2 并返回 1；配对 1+1 可保持一条完成路径并返回 2。该反例应把首错定位到 S4。

7.3 金币：Critic 上下文不完整产生误报

run_25X8tgq2qpxb0Yyc 的 S1 使用 coin.in/coin.out。过程评估器只从 manifest 的 stdin_and_file/stdout_or_file 推断文件 I/O 可选，因而认为该行为可能导致运行错误；但 Solver 提示和 Workspace 校验明确强制 exact freopen，缺失时会触发 REQUIRED_FILE_IO_MISSING。该告警来自评审上下文缺失，辅助复核判为误报。

7.4 廊桥分配、超速检测、建造军营：定位可转化为修复

廊桥分配在 S2 复用最早释放编号而非最小空闲编号；超速检测在 S3 错把负加速度车辆的判定谓词当作全局单调；建造军营在 S8 的桥树 DP 漏计当前分量权重。三者均有小规模反例，机器首错分别命中 S2、S3、S8，修复后达到 20/20、10/10、20/20。

8. 模型能力边界与临界点

能力层面	已验证能力	当前边界
基础算法与实现	入门至普及题目级严格成功 23/23	提高档开始出现证明与实现分离
首错定位	有显式反例时可定位并指导修复	共享贪心假设会让两路 Critic 同时漏检
答案/过程解耦	识别 13 条答案正确但过程无效	I/O 等工作流约束未完整传递会误报
高难度求解	个别省选题可修复至 AC	省选/NOI-严格成功 1/9，NOI/CTS 0/4
资源控制	可区分 WA、TLE、RE 并保留混合失败	高难度下复杂度修复常在轮数上限前不收敛

综合难度数据与案例，当前系统的稳定区间为入门至普及，过渡区间为普及+/提高-至提高+/省选-，明显下降区间为省选/NOI-及以上。

9. 风险与改进建议

- 统一成功口径** 修复 campaign 的历史跳过条件和 fully_passing_runs：必须要求 final/best.complete=true，而不是仅 status=COMPLETED 或测试点全过。
- 冻结正式实验队列** 发布 run_id 清单和代码版本，分别报告单次实验、历史至少一次覆盖、修复后最佳结果，避免重复运行造成分母漂移。
- 先小例再盲审** 难题先执行公开样例、微型穷举或差分 oracle；判题失败但 Critic 全部 SUPPORTED 时，把冲突本身视为必须解决的质量门禁。

- 4. **补全 Critic 权限内上下文** 向评审传递工作流级 I/O、安全和输出约束，避免 manifest 局部信息导致误报。
- 5. **强制可解释的未定位** 错误答案若无法给出首错步骤，应标记 NOT_ASSESSABLE/UNRESOLVED 并进入复核队列，不能同时声称 process_correct=true。
- 6. **完成双人人工盲标** 两名评审独立填写真实过程、首错和类型，分歧裁决并写入 annotations；随后使用现有脚本计算正式定位准确率与误报率。

10. 结论

Hy3-ContestLens 已经形成可运行的结构化解题、双路过程评审、确定性判题、首错融合与修复复验闭环。63 道可自动评测题全部有已结束结果，53 道至少一次答案 AC，44 道至少一次答案与过程双通过。修复使运行级严格成功净增 10 条。

模型的主要边界出现在省选/NOI-以上：复杂度约束、局部贪心可延拓性和评审与判题冲突成为主导失败来源。过程评估器能发现 Judge-only 无法覆盖的证明问题，也存在共享盲点和上下文型误报。正式提交前的关键补齐项是双人人工盲标与裁决；在此之前，辅助预审的 50.0% 定位匹配和 25.0% 告警误报只能作为工程风险信号。

提交就绪判断

完整结果表格、版本级验证数据和人工抽检工作表已具备；正式定位准确率与误报率仍待人审签字。完成该步骤后即可把当前报告中的“辅助预审”替换为正式验证结论。

附录 A 错误分类体系

类别	枚举	判定说明
题意与约束	STATEMENT_MISREAD / CONSTRAINT_OMISSION	题意误读或漏掉必要条件
算法与证明	WRONG_ALGORITHM / PROOF_GAP / CIRCULAR_REASONING / HALLUCINATED_CLAIM	核心方法错误、证明不充分、循环论证或无依据陈述
资源与边界	COMPLEXITY_TLE / COMPLEXITY_MLE / BOUNDARY_ERROR / INTEGER_OVERFLOW	时间、空间、边界或整数范围错误
实现	STATE_TRANSITION_ERROR / IMPLEMENTATION_MISMATCH / IO_OR_FORMAT_ERROR / COMPILE_ERROR / RUNTIME_ERROR	状态、代码映射、格式、编译或运行错误
特殊	RESULT_CORRECT_PROCESS_INVALID / UNRESOLVED	答案正确但过程无效；或证据不足无法归类

附录 B 人工复核协议

1. 两名评审者仅查看冻结的题面、Solver 步骤、源码、Judge 结果与公开反例，彼此标签隔离。
2. 先判 final_result_correct，再判 process_correct；若过程错误，记录拓扑序最早的错误步骤和固定枚举类型。
3. 每条标签至少写一项可复核证据；允许 NOT_ASSESSABLE，但不得用空值表示“正确”。
4. 分歧样本由第三方裁决，保留两份原始标签与 adjudication，不覆盖历史记录。
5. 人审完成后，用错误答案样本计算首错完全匹配率；对答案正确且被机器告警的样本计算真实问题比例与误报率。

附录 C 主要证据文件

用途	路径
任务要求	G:/hy3/Real_Obj/犀牛鸟开源-实战任务-混元大语言模型项目.pdf（第 3-4 页）
运行数据库	runs/contestlens.sqlite3
两轮活动	G:/hy3/campaigns/collection-20260910T103603Z 与 collection-20260911T013612Z
评估方法	docs/EVALUATION_METHOD.md
错误分类	docs/ERROR_TAXONOMY.md
真实工作流程验收	docs/WORKFLOW_LIVE_TEST_20260909.md
失败案例复现	docs/TREE_RUN_ANALYSIS_20260908.md
运行级结果	outputs/evaluation_20260911/complete_run_results.csv
版本级验证	outputs/evaluation_20260911/revision_validation_data.jsonl
人工抽检台账	outputs/evaluation_20260911/manual_audit_records.csv